

Christian SONTSA KITEU

AI ENGINEER (LLM & RAG)

Paris, France | Email : sontsachristian@gmail.com | Tel : +33 7 66 51 41 33 | LinkedIn : [Christian SONTSA](#)

Disponible immédiatement — Mobilité nationale et internationale

PROFIL PROFESSIONNEL

Data Engineer de plus de 05 ans d'expérience, actuellement alternant au sein de l'équipe Data / IA / Engineering du Groupe Harvest, où je conçois et industrialise des systèmes d'IA générative (RAG hybride, agents LLM, LLMOps) au service des produits patrimoniaux du groupe. Solide culture software engineering (Python, SQL, Airflow, architectures modulaires) associée à une expertise opérationnelle en architectures RAG production-grade, évaluation continue et réduction des hallucinations. À l'aise dans des environnements complexes et réglementés (finance patrimoniale), autonome, orienté qualité, sécurité et valeur produit.

COMPÉTENCES CLÉS

- **IA générative & RAG** : pipelines RAG hybrides (vectoriel + lexical + reranking), Contextual Retrieval, chunking, embeddings, orchestration LangGraph, mémoire conversationnelle, réduction des hallucinations, grounding et citations, frameworks d'évaluation (LLM-as-judge, métriques type RAGAS).
- **LLMOps & industrialisation** : monitoring (latence, coûts, qualité, dérive), versioning de prompts/chaînes, tests automatisés, CI/CD.
- **Machine Learning** : XGBoost, scikit-learn, feature engineering, optimisation d'hyperparamètres (RandomizedSearchCV, validation croisée), tests property-based (Hypothesis).
- **Data Engineering** : pipelines ETL/ELT, intégration multi-sources, orchestration Airflow, contrôle qualité, industrialisation des flux.
- **Langages & outils** : Python (avancé), SQL (avancé), JavaScript / Next.js, FastAPI, Qdrant, PostgreSQL, Docker, Airflow, Git/GitLab, Alteryx, DBeaver, Power BI, Tableau, Rancher, ArgoCD.
- **Sécurité & conformité** : bonnes pratiques de sécurité, respect des règles de gestion, secteur réglementé (finance patrimoniale).
- **Environnements** : AWS, Azure, Salesforce, API, bases relationnelles, méthodes Agile/Scrum.

EXPÉRIENCES PROFESSIONNELLES

Data Engineer & Support BI (Alternance) — Groupe Harvest · France

09/2025 – 09/2026 (poste actuel)

- Conception et industrialisation d'un agent conversationnel IA générative (RAG hybride) pour la documentation produit O2S, en architecture hexagonale testable et évolutive.
- Développement d'un pipeline RAG production-grade : ingestion, chunking, Contextual Retrieval, recherche hybride vectorielle + lexicale (Qdrant + BM25), reranking LLM, génération augmentée.
- Mise en place d'un framework d'évaluation automatisée (125 questions de test, LLM-as-judge) : Faithfulness/Relevancy 93 %, Completeness 88 %, latence P95 < 12 s, taux d'hallucination mesuré et réduit à 12 % après correction méthodologique.
- Conception et déploiement d'un modèle ML (XGBoost) de prédiction du churn client, avec feature engineering sur données d'usage, optimisation d'hyperparamètres et tests property-based ; sortie mensuelle exploitée par les équipes commerciales.
- Construction d'une base d'entraînement consolidée (16 sources de données, jointures complexes) pour un futur modèle de Deep Learning de prédiction du churn pour le produit O2S.
- Automatisation des flux de collecte et de traitement (Python, Airflow), mise en place de contrôles qualité, collaboration avec les équipes BI, IT et métiers.

Stack : Python, FastAPI, LangGraph, Qdrant, BM25, LLM (OpenAI, Cohere), Next.js, XGBoost, scikit-learn, Airflow, SQL, Tableau, Salesforce, GitLab, DBeaver, API

Stagiaire BI & Data Visualisation — Harvett Conseils Risque et Finances · France

02/2025 – 06/2025

- Intégré et consolidé des données provenant de sources multiples afin d'alimenter un socle de données exploitable pour l'analyse et le reporting.
- Préparé, transformé et normalisé les jeux de données avec Alteryx et Python pour améliorer leur qualité et faciliter leur réutilisation par les équipes.
- Contribué à la structuration des données nécessaires à la production de tableaux de bord Power BI et à la restitution de KPI fiables aux interlocuteurs métiers.

Stack : Power BI, Alteryx, Python, Excel, fichiers plats

Data Analyst & BI (CDI) — Honeywell · Émirats Arabes Unis

11/2020 – 12/2024

- Centralisé et intégré des données multi-sources issues de bases relationnelles, fichiers, API et SAP afin d'alimenter des usages analytiques dans un environnement international.

- Développé et optimisé des traitements de préparation et de transformation de données avec SQL, Python et VBA pour améliorer les performances et réduire les délais de mise à disposition.
- Mis en place des processus de fiabilisation et de contrôle pour garantir la cohérence, la disponibilité et la qualité des données utilisées par les équipes métiers.
- Travaillé en collaboration avec les équipes métier et BI pour fournir des datasets et reportings adaptés aux besoins de pilotage et de prise de décision.

Stack : SQL, Python, Power BI, Excel (VBA), SAP, API, bases relationnelles

PROJETS TECHNIQUES SÉLECTIONNÉS

Kiss My Agent V3 — Assistant IA documentaire O2S

Agent conversationnel avec RAG hybride pour répondre aux questions des utilisateurs sur la documentation O2S.

- Architecture hexagonale (ports & adapters) — testable, modulaire, évolutive.
- RAG hybride : Contextual Retrieval (Anthropic) — vectoriel + lexical + reranking LLM.
- Mémoire conversationnelle : gestion des threads via LangGraph MemorySaver.
- Évaluation automatisée : 125 questions de test, LLM-as-judge, métriques type RAGAS.
- Résultats : Relevancy/Faithfulness 93 % · Completeness 88 % (amélioration continue) · Latence P95 < 12 s · Hallucination 12 % après correction méthodologique.

Stack : Python, FastAPI, LangGraph, Qdrant, BM25, OpenAI gpt-5.1, Cohere embed-v4, Next.js, LangChain, Langfuse

Pipeline de prédiction du churn (BIG)

Modèle ML pour détecter les clients à risque de résiliation dans le mois suivant.

- Feature engineering sur données d'usage BIG.
- Optimisation d'hyperparamètres (RandomizedSearchCV, validation croisée 3-fold).
- Tests property-based (Hypothesis) pour garantir la robustesse.
- Sortie mensuelle exploitée par les équipes commerciales.

Stack : Python, XGBoost, scikit-learn, pandas

O2S Churn — Base d'entraînement (en cours)

Construction d'un dataset consolidé pour la prédiction du churn sur O2S et mise en place d'un modèle de Deep Learning pour prédire le churn du produit O2S (en cours).

- Cartographie des fichiers sources, jointures complexes, agrégations par contact/société.
- Feature engineering avancé pour un futur modèle Deep Learning.

Second Brain — équipe Data & IA

Contribution active à la base de connaissance de l'équipe (pattern LLM Wiki de Karpathy).

- Rédaction de doctrines, ADR et fiches projet.
- Alimentation continue des sources documentaires.

FORMATION

- | | |
|--|-------------|
| • MBA II Big Data & Intelligence Artificielle | 2025 – 2026 |
| • Licence Informatique – Option Systèmes & Réseaux | 2017 – 2020 |

CERTIFICATIONS

- AWS Data Center Technician — Terminé
- Microsoft Power BI Data Analyst Associate (PL-300) — En cours (90%)
- Alteryx Designer Core — Terminé
- Snowflake Datawarehouse — Terminé
- AWS AI Practitioner – En cours (45%)

LANGUES

- Français : Langue maternelle
- Anglais : Professionnel courant B2/C1